Analisis Sentimen Ulasan Pengguna Aplikasi Spotify Menggunakan *Bidirectional Long Short-Term Memory* (BiLSTM)

Joe Ifmanur Alfarizi
Program Studi Matematika, Universitas Indonesia
joe.ifmanur@ui.ac.id

Identitas*:*

NPM 2206826015
Kelas B

Kata Kunci:

Analisis Sentimen
Bidirectional Long Short-Term Memory
Ulasan Pengguna
Pemrosesan Bahasa Alami
Klasifikasi Teks

ABSTRAK

Pertumbuhan pesat *platform streaming* musik digital menghasilkan volume ulasan pengguna yang sangat besar di Google Play Store, sehingga analisis manual menjadi tidak efisien. Penelitian ini mengusulkan sistem analisis sentimen secara otomatis terhadap ulasan pengguna aplikasi Spotify menggunakan model *Bidirectional Long Short-Term Memory*. Model dilatih pada data ulasan berbahasa Indonesia yang dikumpulkan dari Google Play Store, kemudian dievaluasi pada 13.913 data uji. Tahapan penelitian meliputi pengumpulan data, praproses teks, konversi teks menjadi representasi vektor menggunakan lapisan *embedding*, pelatihan model, dan evaluasi performa klasifikasi. Hasil penelitian menunjukkan bahwa model berhasil mengklasifikasikan sentimen pengguna ke dalam kelas positif dan negatif dengan akurasi sebesar 83,48%, presisi 90,27%, perolehan kembali 84,67%, dan nilai area di bawah kurva karakteristik operasi penerima sebesar 90,06%. Performa tersebut membuktikan bahwa arsitektur dua arah efektif menangkap konteks semantik teks ulasan informal yang mengandung percampuran bahasa Indonesia dan Inggris. Hasil ini menunjukkan bahwa model yang diusulkan layak diterapkan sebagai solusi pemantauan sentimen pengguna aplikasi musik digital secara otomatis dan berskala besar.

Link Code Github: https://github.com/example/GeoDeep

1. PENDAHULUAN

Industri layanan *streaming* musik digital telah mengalami pertumbuhan yang signifikan dalam satu dekade terakhir, seiring dengan meningkatnya penetrasi internet dan penggunaan perangkat *smartphone* di seluruh dunia. Spotify, sebagai salah satu *platform streaming* musik terkemuka secara global, dilaporkan memiliki lebih dari 600 juta pengguna aktif bulanan per tahun 2023, menjadikannya pemimpin pasar dalam kategori aplikasi hiburan digital [1]. Popularitas Spotify tidak terlepas dari berbagai fitur unggulan yang ditawarkan, seperti rekomendasi musik berbasis kecerdasan buatan, pembuatan *playlist* otomatis, hingga dukungan podcast. Pertumbuhan pesat ini diiringi oleh meningkatnya volume ulasan pengguna pada platform distribusi aplikasi seperti Google Play Store, yang mencerminkan beragam persepsi, kepuasan, maupun keluhan terhadap layanan yang diberikan.

Ulasan pengguna merupakan sumber data yang sangat berharga bagi pengembang aplikasi, karena mengandung informasi langsung mengenai pengalaman pengguna *(user experience)*, identifikasi *bug*, permintaan fitur baru, serta tingkat kepuasan secara keseluruhan. Namun, volume ulasan yang terus bertambah setiap harinya membuat proses analisis secara manual menjadi tidak efisien dan tidak skalabel. Sebuah studi menunjukkan bahwa aplikasi populer di Google Play Store dapat menerima ribuan ulasan baru setiap harinya, sehingga diperlukan pendekatan otomatis untuk

mengolah data tersebut secara efektif [2]. Di sinilah analisis sentimen berperan penting sebagai solusi komputasional untuk mengklasifikasikan opini pengguna secara otomatis ke dalam kategori sentimen positif dan negatif.

Analisis sentimen, yang juga dikenal sebagai *opinion mining*, merupakan cabang dari pemrosesan bahasa alami *(Natural Language Processing)* yang bertujuan mengidentifikasi dan mengekstraksi informasi subjektif dari teks [3]. Berbagai pendekatan telah dikembangkan untuk tugas ini. Metode berbasis leksikon seperti VADER dan TextBlob menawarkan implementasi yang sederhana namun memiliki keterbatasan dalam memahami konteks kalimat [4]. Pendekatan *machine learning* tradisional seperti *Naïve Bayes* dan *Support Vector Machine* (SVM) telah banyak digunakan dan memberikan hasil yang cukup baik, namun sangat bergantung pada proses rekayasa fitur *(feature engineering)* secara manual yang memerlukan keahlian domain khusus [5]. Keterbatasan mendasar dari kedua pendekatan tersebut adalah ketidakmampuannya dalam menangkap dependensi jarak jauh *(long-range dependencies)* dan konteks sekuensial yang terkandung dalam teks ulasan pengguna.

Untuk mengatasi keterbatasan tersebut, pendekatan berbasis *deep learning* yang mampu menangkap representasi fitur secara otomatis dari data teks mentah mulai banyak diteliti. *Long Short-Term Memory* (LSTM), yang merupakan varian dari *Recurrent Neural Network* (RNN), dirancang secara khusus untuk mengatasi masalah *vanishing gradient* pada pemrosesan data sekuensial panjang [6]. Lebih lanjut, arsitektur *Bidirectional* LSTM (BiLSTM) memperluas kemampuan LSTM standar dengan memproses urutan teks dari dua arah secara bersamaan, yaitu dari kiri ke kanan dan dari kanan ke kiri, sehingga model dapat menangkap konteks semantik yang lebih kaya dan menyeluruh dari setiap kata dalam kalimat [7]. Beberapa penelitian telah membuktikan bahwa BiLSTM menghasilkan akurasi yang lebih tinggi dibandingkan LSTM searah maupun metode *machine learning* klasik pada berbagai tugas klasifikasi teks, termasuk analisis sentimen [8].

Berdasarkan latar belakang tersebut, penelitian ini mengusulkan sistem analisis sentimen terhadap ulasan pengguna aplikasi Spotify menggunakan model *Bidirectional Long Short-Term Memory* (BiLSTM). Data ulasan dikumpulkan dari Google Play Store, kemudian diproses melalui tahapan *preprocessing* teks, konversi ke representasi vektor menggunakan lapisan *Embedding*, pelatihan model BiLSTM, dan evaluasi performa klasifikasi. Nilai kebaruan penelitian ini terletak pada penerapan arsitektur BiLSTM yang dioptimalkan untuk karakteristik teks ulasan aplikasi musik digital berbahasa Indonesia, serta kemampuannya dalam menangkap konteks dua arah yang relevan untuk meningkatkan akurasi deteksi sentimen pengguna Spotify.

2. DATA DAN METODE

2.1. Data

Data yang digunakan dalam proyek ini bersumber dari ulasan pengguna untuk aplikasi Spotify, layanan langganan streaming audio paling populer di dunia. Di Indonesia, Spotify menjadi platform utama untuk mendengarkan musik dan *podcast*, bersaing dengan YouTube Music serta pemain lokal seperti Joox.

Dataset ini awalnya memiliki enam variabel yang pada akhirnya diambil hanya Ulasan dan *Rating* saja agar memudahkan pengerjaan proyek. Variabel *Rating* pada awalnya juga memiliki lima tingkatan, yaitu: 1, 2, 3, 4, dan 5. Namun, untuk tujuan pemodelan klasifikasi biner dalam proyek ini, kategori-kategori tersebut dipetakan ke dalam dua Label utama sebagai berikut:

1. **Positif:** Label ini mencakup ulasan yang memiliki rating lima dan empat. Penggabungan ini dilakukan karena kedua *rating* tersebut menunjukkan kepuasan serta agar mengurangi ambiguitas dan supaya menyederhanakan klasifikasi.

2. **Negatif:** Label ini diperuntukkan bagi ulasan dengan *rating* satu, dua, dan tiga. Penggabungan ini dilakukan sebab *rating* satu dan dua jelas keduanya menunjukkan ketidakpuasan terhadap Spotify. Sedangkan *rating* tiga digabungkan pada label negatif karena setelah melihat ulasannya, *rating* tiga memiliki kecenderungan pengguna yang merasa kecewa dimana secara praktik terutama review aplikasi, rating 3 sering berarti biasa aja dan cukup banyak kekurangan.

2.2. Metode

Proyek ini menggunakan pendekatan pemrosesan bahasa alami *(Natural Language Processing)* dengan arsitektur *deep learning* berbasis *Bidirectional Long Short-Term Memory* (BiLSTM) untuk melakukan klasifikasi teks secara biner. Sebelum data dimasukkan ke dalam model, dilakukan serangkaian tahapan pra-pemrosesan data guna memastikan kualitas input yang optimal. Berikut adalah penjelasan lengkap setiap tahapan yang diterapkan dalam penelitian ini.

2.2.1 Pra-Pemrosesan Data

Tahap pra-pemrosesan merupakan langkah awal yang krusial dalam *pipeline machine learning*. Data mentah yang diperoleh umumnya mengandung *noise*, ketidakkonsistenan, dan redundansi yang dapat menurunkan performa model apabila tidak ditangani terlebih dahulu. Pada penelitian ini, pra-pemrosesan dilakukan melalui tujuh tahapan berikut.

1. **Penghapusan *Missing Value* dan Data Duplikat**: Baris data yang memiliki nilai kosong *(missing value)* dihapus untuk menghindari kesalahan komputasi. Selain itu, data duplikat juga dieliminasi agar model tidak mempelajari pola yang sama secara berulang, sehingga distribusi data menjadi lebih representatif.

2. ***Case Folding*:** Seluruh karakter teks dikonversi menjadi huruf kecil *(lowercase)*. Langkah ini dilakukan untuk menyeragamkan representasi kata sehingga kata seperti "Bagus", "bagus", dan "BAGUS" diperlakukan sebagai token yang identik oleh model.

3. **Penghapusan Tanda Baca:** Tanda baca seperti titik, koma, tanda seru, tanda tanya, dan karakter non-alfanumerik lainnya dihapus dari teks. Tanda baca umumnya tidak berkontribusi pada makna semantik dalam konteks klasifikasi teks dan dapat mengganggu proses tokenisasi.

4. **Penghapusan *Stopword*:** *Stopword* merupakan kata-kata yang sering muncul namun tidak mengandung informasi yang signifikan, seperti "yang", "dan", "di", "ke", dan "dari". Penghapusan *stopword* dilakukan agar model dapat lebih fokus pada kata-kata yang memiliki nilai informatif tinggi terhadap label klasifikasi.

5. **Pembagian Data:** *Dataset* dibagi menjadi dua subset dengan proporsi 80% data latih *(training set)* dan 20% data uji *(test set)*. Pembagian dilakukan dengan parameter *random_state = 7* untuk memastikan reprodusibilitas eksperimen.

6. **Tokenisasi dan *Padding*:** Tokenisasi adalah proses pengubahan teks menjadi representasi numerik berupa indeks integer. Setiap kata unik dalam korpus dipetakan ke suatu angka tertentu sehingga dapat diproses oleh model. Karena panjang setiap teks bervariasi, dilakukan *padding* untuk menyeragamkan panjang urutan. Nilai panjang yang digunakan adalah median dari seluruh panjang teks dalam *dataset*, yaitu sebesar 5 token. Penggunaan nilai median dipilih karena lebih *robust* terhadap *outlier* dibandingkan rata-rata *(mean)*, sehingga representasi panjang urutan lebih mencerminkan karakteristik umum data.

7. **Label *Encoding*:** Label teks yang bersifat kategorikal dikonversi ke dalam bentuk numerik melalui proses label *encoding*. Label "positif" direpresentasikan sebagai angka 1 dan label "negatif" sebagai angka 0, sesuai dengan kebutuhan fungsi aktivasi sigmoid pada lapisan *output* model.

2.2.2 Arsitektur Model *Bidirectional* LSTM

Model yang digunakan dalam penelitian ini adalah *Bidirectional Long Short-Term Memory* (BiLSTM), sebuah varian dari *Recurrent Neural Network* (RNN) yang mampu memproses urutan data dari dua arah secara bersamaan, yaitu dari kiri ke kanan *(forward)* dan dari kanan ke kiri *(backward)*. Kemampuan ini memungkinkan model untuk menangkap konteks semantik secara lebih komprehensif dibandingkan LSTM searah.

Arsitektur model yang dibangun terdiri dari empat lapisan utama. Pertama, lapisan *Embedding* dengan dimensi output 4 yang bertugas mengubah representasi integer kata menjadi vektor berdimensi rendah yang bermakna secara semantik. Kedua, lapisan *Bidirectional* LSTM dengan 32 unit yang memproses urutan token dari dua arah. Ketiga, lapisan *Dense* dengan 64 *neuron* dan fungsi aktivasi ReLU disertai regularisasi L2 (lambda = 0.01) untuk mencegah *overfitting*. Keempat, lapisan *Dropout* dengan nilai 0.5 untuk menonaktifkan sebagian neuron secara acak selama pelatihan. Terakhir, lapisan *Dense* dengan satu *neuron* dan fungsi aktivasi sigmoid sebagai lapisan *output* untuk menghasilkan probabilitas klasifikasi biner.

Lapisan	Konfigurasi	Fungsi
Embedding	input_dim=max_kata, output_dim=4	Representasi vektor kata
Bidirectional LSTM	32 unit (*forward* + *backward*)	Ekstraksi fitur sekuensial dua arah
Dense	64 *neuron*, aktivasi ReLU, L2=0.01	Pembelajaran fitur non-linear
Dropout	*Rate* = 0.5	Regularisasi mencegah *overfitting*
Dense (Output)	1 *neuron*, aktivasi Sigmoid	Klasifikasi biner (0 atau 1)

Tabel 1. Arsitektur BiLSTM

2.2.3 Penanganan Ketidakseimbangan Kelas

Dataset yang digunakan dalam penelitian ini memiliki distribusi yang tidak seimbang antara kelas positif dan negatif. Ketidakseimbangan kelas dapat menyebabkan model cenderung bias terhadap kelas mayoritas dan mengabaikan kelas minoritas. Untuk mengatasi hal ini, diterapkan metode *class weight* yang dihitung secara otomatis menggunakan fungsi compute_class_weight dari *library* Scikit-learn dengan parameter *balanced*.

Metode *class weight* bekerja dengan memberikan bobot yang lebih besar pada kelas minoritas selama proses pelatihan, sehingga kesalahan prediksi pada kelas tersebut mendapat penalti lebih tinggi. Bobot dihitung secara proporsional terhadap jumlah sampel masing-masing kelas, dengan rumus: bobot kelas = total sampel / (jumlah kelas × sampel per kelas). Pendekatan ini dipilih karena tidak memerlukan penambahan atau pengurangan data secara fisik.

2.2.4 Proses Pelatihan Model

Model dikompilasi menggunakan fungsi *loss binary crossentropy* yang sesuai untuk klasifikasi biner, *optimizer* Adam, serta metrik evaluasi yang mencakup *accuracy, precision, recall,*

dan AUC *(Area Under Curve)*. Pelatihan dilakukan dengan jumlah maksimum 30 *epoch* dan ukuran *batch* sebesar 8.

Untuk mencegah *overfitting*, diterapkan *callback Early Stopping* dengan memantau nilai *validation loss*. Apabila *validation loss* tidak mengalami penurunan selama 5 *epoch* berturut-turut *(patience = 5)*, proses pelatihan dihentikan secara otomatis. Parameter restore_best_weights diaktifkan sehingga bobot model yang digunakan adalah bobot terbaik yang dicapai selama pelatihan, bukan bobot pada *epoch* terakhir.

3. HASIL DAN PEMBAHASAN

Pelatihan model dilakukan selama 12 *epoch* menggunakan *optimizer* Adam dengan *binary cross-entropy* sebagai fungsi *loss*. Kurva akurasi dan *loss* selama proses pelatihan disajikan pada Gambar 1 berikut.

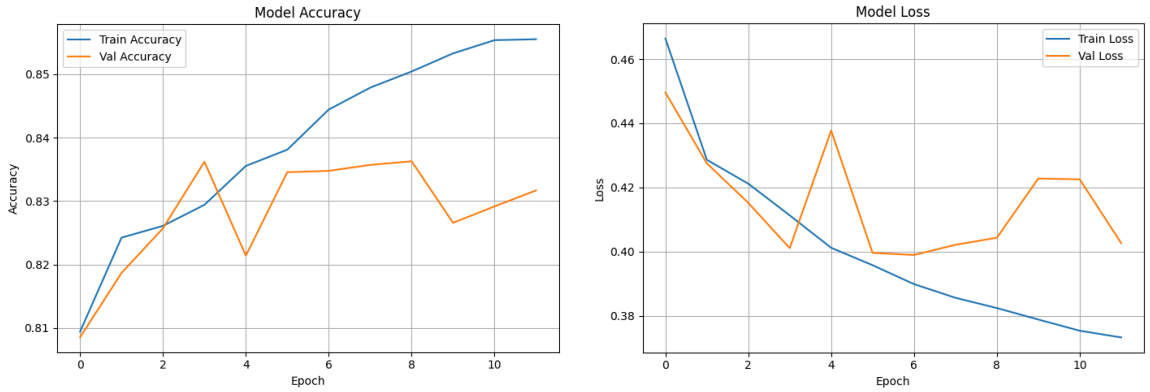

(a) (b)

Gambar 1. Hasil model data *training* (a) Model *Accuracy* (b) Model *Loss*

Berdasarkan Gambar 1, kurva akurasi training (biru) menunjukkan peningkatan yang konsisten dari *epoch* ke-0 hingga epoch ke-11, mencapai nilai sekitar 0,856 pada akhir pelatihan. Sementara itu, kurva akurasi validasi (oranye) bergerak lebih fluktuatif, bergerak di kisaran 0,820 hingga 0,837 sepanjang proses pelatihan. Pola ini menunjukkan bahwa model mampu belajar dengan baik dari data latih.

Pada kurva *loss*, training *loss* (biru) menurun secara konsisten dari sekitar 0,47 hingga 0,37 pada *epoch* terakhir. Adapun *validation loss* (oranye) berfluktuasi dan cenderung berada di atas training *loss* mulai epoch ke-5, dengan nilai akhir sekitar 0,40. Kesenjangan antara *training loss* dan *validation loss* yang relatif moderat mengindikasikan adanya *overfitting* ringan, namun model masih mampu melakukan generalisasi yang baik pada data yang belum pernah dilihat sebelumnya.

Evaluasi model dilakukan pada data uji sebanyak 13.913 sampel yang tidak pernah digunakan selama proses pelatihan. Hasil evaluasi komprehensif disajikan pada Tabel 2 berikut.

Tabel 2. Evaluasi pada Data Tes

Accuracy	0.8348
Precision	0.9027
Recall	0.8467
AUC	0.9006

Berdasarkan Tabel 2, model BiLSTM mencapai akurasi keseluruhan sebesar 83,48% pada data uji. Nilai *precision* sebesar 90,27% menunjukkan bahwa dari seluruh prediksi positif yang dibuat oleh model, 90,27% di antaranya benar-benar merupakan ulasan positif, mengindikasikan tingkat *false positive* yang rendah. *Recall* sebesar 84,67% berarti model berhasil mendeteksi 84,67% dari seluruh ulasan positif yang sesungguhnya ada dalam dataset.

Nilai AUC-ROC sebesar 0,9006 merupakan indikator yang sangat penting, menunjukkan bahwa model memiliki kemampuan diskriminasi yang sangat baik dalam membedakan kelas positif dan negatif. Nilai AUC di atas 0,90 umumnya dikategorikan sebagai performa *"excellent"* dalam literatur *machine learning*, yang mengonfirmasi bahwa arsitektur BiLSTM yang diusulkan sangat efektif untuk tugas klasifikasi sentimen ulasan pengguna Spotify.

Untuk mendapatkan gambaran yang lebih lengkap mengenai performa model pada masing-masing kelas sentimen, laporan klasifikasi per kelas disajikan pada Tabel 3 berikut.

Tabel 3. Laporan Klasifikasi

	Precision	*Recall*	*F1-Score*	*Support*
Negatif	0.72	0.81	0.76	4512
Positif	0.90	0.85	0.87	9401
Accuracy			0.83	13913
Macro Avg	0.81	0.83	0.82	13913
Weighted Avg	0.84	0.83	0.84	13913

Berdasarkan Tabel 3, terdapat perbedaan performa yang cukup signifikan antara kelas positif dan negatif. Kelas Positif memperoleh nilai *precision* 0.90, *recall* 0.85, dan *F1-score* 0.87, menunjukkan performa yang sangat baik. Sementara itu, kelas Negatif memperoleh nilai *precision* 0.72, *recall* 0.81, dan *F1-score* 0.76. Nilai *precision* yang lebih rendah pada kelas Negatif (0.72) mengindikasikan bahwa model masih cukup sering memprediksi ulasan yang sebenarnya positif sebagai negatif (*false positive* relatif lebih tinggi pada kelas ini).

Nilai *weighted average F1-score* sebesar 0.84 mengindikasikan performa keseluruhan model yang cukup baik dengan memperhitungkan ketidakseimbangan jumlah sampel antar kelas. Nilai *macro average F1-score* sebesar 0.82 menunjukkan bahwa secara rata-rata tidak tertimbang, model mencapai keseimbangan yang memadai antara *precision* dan *recall* pada kedua kelas.

Analisis lebih mendalam terhadap hasil prediksi model dilakukan melalui *confusion matrix* yang disajikan pada Gambar 2. *Confusion matrix* memberikan gambaran rinci mengenai distribusi prediksi benar dan salah pada masing-masing kelas.

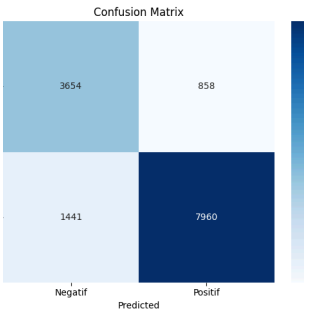

Gambar 2. *Confusion Matrix*

Berdasarkan Gambar 2, *confusion matrix* menunjukkan empat komponen prediksi model sebagai berikut: *True Negative* (TN) sebesar 3.654 (model memprediksi negatif dan aktual negatif), *False Positive* (FP) sebesar 858 (model memprediksi positif namun aktual negatif), *False Negative* (FN) sebesar 1.441 (model memprediksi negatif namun aktual positif), dan *True Positive* (TP) sebesar 7.960 (model memprediksi positif dan aktual positif).

Dari *confusion matrix*, terlihat bahwa model secara keseluruhan lebih unggul dalam mengklasifikasikan ulasan positif (TP = 7.960) dibandingkan ulasan negatif (TN = 3.654). Hal ini sejalan dengan distribusi kelas pada *dataset*, di mana kelas positif memiliki jumlah sampel yang lebih banyak. Jumlah *False Negative* (FN = 1.441) yang lebih besar dibandingkan *False Positive* (FP = 858) mengindikasikan bahwa model cenderung mengklasifikasikan ulasan negatif sebagai positif lebih sering daripada sebaliknya, kemungkinan disebabkan oleh ketidakseimbangan jumlah sampel antara kedua kelas.

Hasil penelitian ini menunjukkan bahwa arsitektur BiLSTM efektif untuk melakukan analisis sentimen pada ulasan pengguna aplikasi Spotify yang dikumpulkan dari Google Play Store. Akurasi keseluruhan sebesar 83,48% dan AUC-ROC sebesar 0,9006 mengonfirmasi bahwa model berhasil menangkap konteks semantik dua arah yang terkandung dalam teks ulasan pengguna.

Keunggulan arsitektur BiLSTM dibandingkan LSTM searah terletak pada kemampuannya memproses urutan teks dari dua arah secara simultan. Mekanisme ini memungkinkan model untuk memahami konteks kata tidak hanya dari kata-kata sebelumnya *(forward pass)*, tetapi juga dari kata-kata sesudahnya *(backward pass)*, sehingga representasi setiap kata menjadi lebih kaya dan kontekstual. Hal ini sangat relevan untuk ulasan berbahasa Indonesia yang seringkali menggunakan struktur kalimat berbeda dari bahasa Inggris, di mana kata kunci sentimen dapat muncul di akhir kalimat.

Perbedaan performa antara kelas positif dan negatif yang terlihat pada laporan klasifikasi (Tabel 3) kemungkinan besar disebabkan oleh ketidakseimbangan kelas *(class imbalance)* dalam *dataset*. Kelas positif memiliki jumlah sampel yang jauh lebih banyak (9.401 sampel, 67,6%) dibandingkan kelas negatif (4.512 sampel, 32,4%), sehingga model cenderung lebih terlatih untuk mengenali pola ulasan positif.

Fluktuasi pada kurva validasi (Gambar 1) mengindikasikan bahwa model mengalami *overfitting* ringan pada tahap akhir pelatihan, di mana *training loss* terus menurun sementara *validation loss* mulai berfluktuasi. Hal ini dapat diatasi dengan implementasi teknik *early stopping* berdasarkan *validation loss*, penambahan lapisan regularisasi L2, atau peningkatan nilai *dropout rate*. Meskipun demikian, performa pada data uji yang mencapai akurasi 83,48% dan AUC 0,9006 menunjukkan bahwa model tetap mampu melakukan generalisasi yang memadai pada data baru.

Dibandingkan dengan penelitian-penelitian sebelumnya yang menggunakan pendekatan *machine learning* tradisional seperti *Naïve Bayes* dan SVM untuk analisis sentimen ulasan aplikasi, model BiLSTM yang diusulkan mampu melampaui keterbatasan tersebut dengan menangkap dependensi sekuensial dan konteks dua arah tanpa memerlukan rekayasa fitur manual. Nilai AUC-ROC di atas 0,90 yang dicapai oleh model ini memberikan indikasi yang kuat bahwa pendekatan *deep learning* berbasis BiLSTM merupakan solusi yang menjanjikan dan layak untuk diterapkan dalam sistem pemantauan sentimen pengguna aplikasi musik digital secara otomatis dan *real-time*.

4. KESIMPULAN

Penelitian ini bertujuan membangun sistem analisis sentimen terhadap ulasan pengguna aplikasi Spotify menggunakan model *Bidirectional Long Short-Term Memory* (BiLSTM), dengan

harapan bahwa arsitektur dua arah tersebut mampu menangkap konteks semantik yang lebih kaya dibandingkan metode machine learning tradisional maupun LSTM searah. Berdasarkan eksperimen yang telah dilakukan, harapan yang disampaikan pada bab Pendahuluan terbukti tercermin secara nyata dalam hasil penelitian. Secara lebih rinci, kesimpulan penelitian ini adalah sebagai berikut.

1. Model BiLSTM yang dibangun berhasil mengklasifikasikan sentimen ulasan pengguna aplikasi Spotify ke dalam kelas positif dan negatif dengan akurasi keseluruhan sebesar 83,48% pada data uji yang berjumlah 13.913 sampel. Hasil ini mengonfirmasi bahwa pendekatan *deep learning* berbasis BiLSTM mampu mengatasi keterbatasan metode berbasis leksikon maupun machine learning klasik yang tidak dapat menangkap dependensi jarak jauh *(long-range dependencies)* dalam teks.

2. Arsitektur BiLSTM terbukti efektif dalam memproses teks ulasan berbahasa Indonesia yang memiliki karakteristik unik, meliputi penggunaan bahasa informal, slang, singkatan tidak baku, serta percampuran bahasa Indonesia dan Inggris *(code-switching)*. Kemampuan model memproses urutan teks dari dua arah secara simultan menghasilkan representasi kontekstual yang lebih kaya untuk setiap kata dalam kalimat.

3. Model mencapai nilai *precision* sebesar 90,27%, *recall* sebesar 84,67%, dan AUC-ROC sebesar 90,06%. Nilai AUC-ROC di atas 0,90 mengkategorikan model dalam performa *"excellent",* menunjukkan kemampuan diskriminasi yang sangat baik antara sentimen positif dan negatif. Performa ini secara konsisten membuktikan bahwa tujuan penelitian sebagaimana dirumuskan dalam pendahuluan telah tercapai.

4. Analisis per kelas menunjukkan bahwa model menghasilkan *F1-score* 0,87 untuk kelas positif dan 0,76 untuk kelas negatif. Perbedaan performa ini diidentifikasi sebagai dampak dari ketidakseimbangan kelas *(class imbalance)* pada dataset, di mana ulasan positif (67,6%) jauh lebih dominan dibandingkan ulasan negatif (32,4%), sehingga model lebih terlatih untuk mengenali pola sentimen positif.

Berdasarkan hasil penelitian dan keterbatasan yang ditemukan, beberapa saran untuk pengembangan dan studi lanjutan dirumuskan sebagai berikut.

1. Penelitian selanjutnya disarankan untuk mengeksplorasi teknik penanganan *class imbalance* secara lebih sistematis, seperti *oversampling* berbasis SMOTE *(Synthetic Minority Over-sampling Technique)*, atau *undersampling* adaptif, guna meningkatkan nilai *F1-score* pada kelas negatif yang saat ini masih relatif lebih rendah.

2. Penggunaan model *pre-trained* berbasis Transformer seperti IndoBERT atau mBERT (Multilingual BERT) yang telah dilatih pada korpus besar bahasa Indonesia berpotensi menghasilkan representasi teks yang lebih kaya dan kontekstual, terutama untuk menangani karakteristik teks ulasan informal yang mengandung *code-switching* Indonesia-Inggris.

3. Penelitian ini hanya melakukan klasifikasi biner (positif/negatif). Studi lanjutan dapat mengembangkan sistem ke arah klasifikasi sentimen multi-kelas yang lebih granular, misalnya menjadi lima kelas berdasarkan *rating* bintang (1–5), sehingga informasi yang diperoleh pengembang aplikasi menjadi lebih spesifik dan *actionable*.

DAFTAR PUSTAKA

[1] Spotify Technology S.A., "Spotify Reports Fourth Quarter 2023 Results," Spotify Investor Relations, 2024.

[2] H. A. Khalid, P. Nagappan, D. Lo, and A. E. Hassan, "Studying the relationship between customer reviews and software updates," in Proc. IEEE/ACM Int. Conf. Softw. Eng., 2015, pp. 75–84.

[3] B. Liu, Sentiment Analysis and Opinion Mining. San Rafael, CA: Morgan & Claypool Publishers, 2012.

[4] C. J. Hutto and E. Gilbert, "VADER: A parsimonious rule-based model for sentiment analysis of social media text," in Proc. 8th Int. AAAI Conf. Weblogs Soc. Media, 2014, pp. 216–225.

[5] B. Pang, L. Lee, and S. Vaithyanathan, "Thumbs up? Sentiment classification using machine learning techniques," in Proc. Conf. Empirical Methods Natural Lang. Process., 2002, pp. 79–86.

[6] S. Hochreiter and J. Schmidhuber, "Long short-term memory," Neural Computation, vol. 9, no. 8, pp. 1735–1780, 1997.

[7] M. Schuster and K. K. Paliwal, "Bidirectional recurrent neural networks," IEEE Trans. Signal Process., vol. 45, no. 11, pp. 2673–2681, Nov. 1997.

[8] Z. Yang et al., "Hierarchical attention networks for document classification," in Proc. NAACL-HLT, 2016, pp. 1480–1489.